


Predictive Maintenance


Raport z Projektu: Przewidywanie awarii maszyn przemysłowych (frezarek CNC) na podstawie danych telemetrycznych.

OLIWIER TRĄBCZYŃSKI

BARTOSZ WANKIEWICZ



Made with GAMMA



Cel Biznesowy i Hipoteza


Głównym celem projektu było opracowanie modelu zdolnego do predykcji usterek frezarek CNC na podstawie danych telemetrycznych z czujników. Rozwiązuje to fundamentalny problem utrzymania ruchu: przejście z kosztownej **konserwacji reaktywnej** (naprawa po zniszczeniu) na **Predictive Maintenance** (zapobieganie awariom z wyprzedzeniem). Analizie poddano syntetyczny zbiór AI4I 2020, symulujący realne parametry, takie jak temperatura procesu czy prędkość obrotowa.

- ❏ **Hipoteza badawcza:** Zastosowanie zaawansowanych modeli uczenia maszynowego opartych na zespołach drzew decyzyjnych (XGBoost) z odpowiednim wagowaniem klas pozwoli na skuteczną predykcję rzadkich awarii z Czułością (Recall) przewyższającą metody klasyczne, optymalizując koszty utrzymania ruchu.

Wyzwanie Techniczne: Paradoks Dokładności


Kluczową barierą był drastyczny brak balansu klas. Maszyny sprawne stanowią **96,6%** zbioru, awarie — zaledwie **3,4%**. W takich warunkach klasyczna metryka *Accuracy* jest bezużyteczna: algorytm zawsze orzekający „maszyna sprawna” osiągnąłby 96,6% dokładności, przegapiając wszystkie usterki. Z tego powodu głównym celem optymalizacyjnym stała się **Czułość (Recall)** – zdolność modelu do wykrywania jak największej liczby rzadkich anomalii.

Analiza braków w danych (funkcja `isnull`) wykazała, że zbiór jest w 100% kompletny. Z macierzy korelacji wynika silna zależność między zmienną docelową a momentem obrotowym i zużyciem narzędzia.



Analiza Danych i Macierz Korelacji

Zbiór AI4I 2020 obejmuje **10 000 rekordów** i 14 kolumn. Kompletność danych potwierdzono funkcją `isnull()` — brak wartości pustych. Macierz korelacji ujawnia silną zależność między zmienną docelową (Machine failure) a **momentem obrotowym** (0,19) i **zuciem narzędzia** (0,11).




```
print("ANALIZA BRAKOW W DANYCH")
missing_values = df.isnull().sum()
print(missing_values)
```

INFORMACJE O TYPACH ZMIENNYCH
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 14 columns):

- # Column Non-Null Count Dtype
- 0 UDI 10000 non-null int64
- 1 Product ID 10000 non-null object
- 2 Type 10000 non-null object
- 3 Air temperature [K] 10000 non-null float64
- 4 Process temperature [K] 10000 non-null float64
- 5 Rotational speed [rpm] 10000 non-null int64
- 6 Torque [Nm] 10000 non-null float64
- 7 Tool wear [min] 10000 non-null int64
- 8 Machine failure 10000 non-null int64
- 9 TWf 10000 non-null int64
- 10 HDF 10000 non-null int64
- 11 PWF 10000 non-null int64
- 12 OSF 10000 non-null int64
- 13 RNF 10000 non-null int64

dtypes: float64(3), int64(9), object(2)
memory usage: 1.1+ MB

ANALIZA BRAKÓW W DANYCH
UDI 0
Product ID 0
Type 0
Air temperature [K] 0
Process temperature [K] 0
Rotational speed [rpm] 0
Torque [Nm] 0
Tool wear [min] 0
Machine failure 0
TWf 0
HDF 0
PWF 0
OSF 0
RNF 0
dtype: int64



Aktualny Stan Wiedzy

1

Klasyczne algorytmy nadzorowane

Random Forest, XGBoost, SVM — binarna klasyfikacja na podstawie zagregowanych cech (temperatura, wibracje). Najczęstszy wybór w przemyśle dla danych tabelarycznych.

2

Głębokie uczenie (Deep Learning)


Sieci RNN/LSTM/GRU dla szeregów czasowych — bezpośrednie prognozowanie RUL (Remaining Useful Life) z sekwencyjnych danych telemetrycznych.

3

Detekcja anomalii

Isolation Forest, One-Class SVM, Autoenkodery — podejście nienadzorowane przy skrajnej dysproporcji klas. Uczą się „normalnego” profilu pracy i oflagowują odchylenia.

Analiza Eksploracyjna: Fizyczny Obraz Awarii



Rozkłady gęstości jednoznacznie potwierdzają, że awarie nie mają charakteru losowego – są silnie skorelowane ze skrajnymi odczytami z czujników telemetrycznych:

Prędkość obrotowa

Awarie korelują ze skrajnie niskimi lub bardzo wysokimi obrotami; maszyny sprawne pracują w stabilnym, wąskim przedziale.

Moment obrotowy

Awarie występują przy znacznie wyższej wariancji siły skręcającej, co sugeruje trudności w obróbce twardego materiału.

Zużycie narzędzia

Najsilniejszy wskaźnik. Mediana czasu pracy dla maszyn uszkodzonych drastycznie przesunięta w górę — tępy frez krytycznie zwiększa ryzyko usterki.

Wybór Modelu: Las Losowy vs XGBoost

Odrzucone kandydatury: **SVM** (wrażliwy na skalowanie, duży narzut obliczeniowy, trudność w ważeniu klas) oraz **Regresja Logistyczna** (zakłada liniowość — złożona fizyka pracy frezarki uniemożliwia skuteczne mapowanie anomalii). W fazie implementacji zderzono dwa algorytmy oparte na zespołach drzew decyzyjnych z wagowaniem klas.

Random Forest (Bagging)

Recall dla klasy awarii: **0,69** — przeoczył aż 31% usterek.
Niewystarczający przy silnym niezbalansowaniu danych.

XGBoost (Boosting) — ZWYCIĘZCA

Recall dla klasy awarii: **0,82**. Każde kolejne drzewo uczy się na błędach poprzednika, skupiając się na źle sklasyfikowanych maszynach. Wbudowane wagi klas priorytetyzują rzadkie awarie.

=====					
WYNIKI DLA MODELU: XGBOOST					
=====					
	precision	recall	f1-score	support	
0	0.99	0.99	0.99	1932	
1	0.82	0.82	0.82	68	
	accuracy	0.99	2000		
	macro avg	0.91	0.91	0.91	2000
	weighted avg	0.99	0.99	0.99	2000
=====					
WYNIKI DLA MODELU: RANDOM FOREST (Las Losowy)					
=====					
	precision	recall	f1-score	support	
0	0.99	1.00	0.99	1932	
1	0.94	0.69	0.80	68	
	accuracy	0.99	2000		
	macro avg	0.96	0.84	0.90	2000
	weighted avg	0.99	0.99	0.99	2000

Optymalizacja Hiperparametrów (GridSearchCV)

Zastosowano walidację krzyżową ze stratyfikacją (StratifiedKfold), gwarantującą zachowanie 3,4% awarii w każdym podzbiorze. Siatka optymalizowana bezpośrednio pod kątem maksymalizacji metryki **Recall**.

✅ Najlepsze parametry: `learning_rate=0.01`,
`max_depth=3`, `n_estimators=100`

Skok skuteczności: Recall wzrósł z **82%** do **93%**. Do finalnej analizy wytypowano dwa wcielenia algorytmu: model bazowy (domyślne ustawienia) oraz model po GridSearchCV (ekstremalnie czuły).

Najlepsze znalezione parametry:

```
{'learning_rate': 0.01,  
 'max_depth': 3,  
 'n_estimators': 100}
```

=====

WYNIKI DLA ZOPTYMALIZOWANEGO MODELU
XGBOOST

=====

precision recall f1-score support

0 1.00 0.91 0.95 1932



1 0.26 0.93 0.40 68

accuracy 0.91 2000

macro avg 0.63 0.92 0.68 2000



weighted avg 0.97 0.91 0.93 2000

Interpretowalność i Kompromis Biznesowy



Ważność Cech

Model zoptymalizowany całkowicie zignorował kategorię jakości producenta (waga = 0). Twarda fizyka z czujników — **prędkość obrotowa, zużycie narzędzia, moment obrotowy, różnica temperatur** — jest w zupełności wystarczająca do przewidzenia awarii.



Macierze Pomyłek

Model bazowy: Recall 0,82 | Precyzja 0,82 — stabilny „złoty środek” z minimalną liczbą fałszywych alarmów.

Model zoptymalizowany: Recall 0,93 | Precyzja 0,26 — działa jak czuły alarm dymny: wyłapuje 93% awarii kosztem wzrostu fałszywych alarmów.



Symulacja Finansowa i Wniosek Końcowy

Zakładając koszt krytycznej usterki (np. spalanie wrzeciona) na poziomie **15 000 PLN** oraz koszt weryfikacji fałszywego alarmu na **200 PLN**:

Model Bazowy

Strata: **182 400 PLN**

Wyłapuje 82% awarii, ale przeoczone usterki generują wysokie koszty napraw.

Model Zoptymalizowany

Strata: **110 800 PLN**

Ratuje więcej maszyn kosztem tanich wizyt technika przy fałszywych alarmach.



Rekomendacja końcowa: Hipoteza badawcza potwierdzona. Celowe podbicie Czułości na rzadkich danych telemetrycznych pozwala zaoszczędzić ponad **70 000 PLN**. Dobrze skalibrowany model to bezpośrednie narzędzie optymalizacji finansowej zakładu.