

Raport z Projektu: Przewidywanie awarii maszyn (Predictive Maintenance)

Autorzy: Oliwier Trąbczyński, Bartosz Wankiewicz

1. Cel Biznesowy i Problem Badawczy

Głównym celem projektu było opracowanie modelu zdolnego do predykcji usterek maszyn przemysłowych (frezarek CNC) na podstawie danych telemetrycznych z czujników.


Rozwiązuje to fundamentalny problem utrzymania ruchu: przejście z kosztownej konserwacji reaktywnej (naprawa po zniszczeniu maszyny) na **Predictive Maintenance** (zapobieganie awariom z wyprzedzeniem). Analizie poddano syntetyczny zbiór AI4I 2020, symulujący realne parametry, takie jak temperatura procesu czy prędkość obrotowa.

2. Wyzwanie Techniczne: Paradoks Dokładności

Kluczową barierą w projekcie był drastyczny brak balansu klas.


- Maszyny sprawne stanowią 96.6% zbioru.
- Awarie stanowią zaledwie 3.4% zbioru.

W takich warunkach klasyczna metryka *Accuracy* (Dokładność) jest bezużyteczna. Algorytm, który całkowicie zignoruje odczyty i zawsze orzeknie "maszyna sprawna", osiągnąłby 96.6% dokładności, przegapiając przy tym wszystkie rzeczywiste usterki. Z tego powodu głównym celem optymalizacyjnym stała się **Czułość (Recall)** – zdolność modelu do wyłapywania jak największej liczby rzadkich anomalii.



3. Analiza Eksploracyjna: Fizyczny obraz awarii

Przed przystąpieniem do budowy modeli predykcyjnych, kluczowe było zrozumienie natury samych awarii. W tym celu przeprowadzono analizę rozkładów najważniejszych zmiennych ciągłych w podziale na stan maszyny (sprawna vs awaria).



Wnioski z analizy wizualnej: Rozkłady gęstości jednoznacznie potwierdzają, że awarie nie mają charakteru losowego – są silnie skorelowane ze skrajnymi odczytami z czujników telemetrycznych:

- **Prędkość obrotowa (Rotational speed):** Rozkład dla maszyn uszkodzonych jest spłaszczony i rozciągnięty. Awarie korelują ze skrajnie niskimi lub bardzo wysokimi prędkościami, podczas gdy maszyny sprawne pracują w stabilnym, wąskim przedziale.
- **Moment obrotowy (Torque):** Awarie występują przy znacznie wyższej wariancji (rozrzucie) siły skręcającej, co sugeruje trudności w obróbce twardego materiału.
- **Zużycie narzędzia (Tool wear):** To najsilniejszy wizualny wskaźnik. Mediana czasu pracy dla maszyn, które uległy awarii, jest drastycznie przesunięta w górę. Zbyt długa praca jednym narzędziem (np. tępym frezem) krytycznie zwiększa ryzyko usterki.

Dzięki tej analizie zyskaliśmy pewność, że w danych ukryty jest silny, nieliniowy wzorzec, z którym doskonale powinny poradzić sobie modele oparte na drzewach decyzyjnych.

4. Wybór i mechanika Modelu: Las Losowy vs XGBOOST

W fazie implementacji zderzono ze sobą dwa potężne algorytmy oparte na zespołach drzew decyzyjnych: Random Forest (wykorzystujący mechanizm baggingu) oraz XGBoost (wykorzystujący boosting). W obu modelach zastosowano techniki wagowania klas (class_weight oraz scale_pos_weight), aby zmusić algorytmy do kładzenia nacisku na rzadko występujące awarie.

```
=====
WYNIKI DLA MODELU: XGBOOST
=====
              precision    recall  f1-score   support

      0       0.99         0.99         0.99        1932
      1       0.82         0.82         0.82         68

   accuracy                0.99        2000
  macro avg       0.91         0.91         0.91        2000
 weighted avg       0.99         0.99         0.99        2000

=====
WYNIKI DLA MODELU: RANDOM FOREST (Las Losowy)
=====
              precision    recall  f1-score   support

      0       0.99         1.00         0.99        1932
      1       0.94         0.69         0.80         68

   accuracy                0.99        2000
  macro avg       0.96         0.84         0.90        2000
 weighted avg       0.99         0.99         0.99        2000
```

Wnioski z porównania i mechanika algorytmu: Mimo zastosowania zbalansowanych wag, Random Forest okazał się niewystarczający w warunkach silnego niezbalansowania danych – osiągnął Czulość (Recall) dla klasy awarii na poziomie jedynie 0.69 (przeoczył aż 31% usterek). Z kolei XGBoost (Model Bazowy) poradził sobie znacznie lepiej, osiągając Czulość rzędu 0.82.

Dlaczego XGBoost wygrał to starcie? Zamiast budować jeden skomplikowany model, tworzy on zespół (sztafetę) wielu prostych drzew decyzyjnych. Każde kolejne drzewo w sekwencji uczy się na błędach swojego poprzednika, skupiając się na tych maszynach, które wcześniej zostały źle sklasyfikowane. Sekwencyjny sposób uczenia algorytmu XGBoost okazał się idealny do wyłapywania trudnych, nieliniowych anomalii z czujników. Dzięki wbudowanemu parametrowi obsługi wag klas, model został skutecznie zmuszony do priorytetyzowania

mniejszościowych przypadków awarii. Z tego względu to on został wytypowany jako model docelowy.